

BoxBox — Estrategia de neumáticos en Fórmula 1

Propuesta de Trabajo Práctico Integral

Inteligencia Artificial Avanzada — UTN FRBA — 2do Cuatrimestre 2026

Apellido y Nombres	E-Mail	Aporte
Sánchez, Tomás Agustín	(completar)	100%

Fecha de Presentación: (completar)

Resumen

En una carrera de Fórmula 1, el equipo tiene que decidir cuándo parar en boxes y qué neumático poner. Es una decisión difícil: depende del desgaste de la goma, de los rivales cercanos y de si sale un Safety Car.

Este trabajo propone un sistema que **arma el plan de neumáticos de una carrera**: cuántas paradas hacer, en qué vueltas y con qué compuesto. No predice quién gana.

El foco está en la temporada **2026**, la primera del nuevo reglamento. Para entrenar se usan además las temporadas anteriores: se midió que agregarlas mejora el modelo un 56%, aunque el orden de desgaste de los compuestos se haya invertido este año.

La idea central es un **simulador de carrera** y, sobre él, un **Algoritmo Genético** que busca el mejor plan. Como comparación se propone un **agente de Aprendizaje por Refuerzo** que decide vuelta a vuelta.

Estado. El pipeline de datos, el simulador y el algoritmo genético están contruidos y medidos; el agente de refuerzo no. El resultado más importante hasta acá es **negativo y está reportado como tal**: el algoritmo genético apenas le gana a una regla simple, por motivos que la sección 6 explica. La sección 4 documenta además cuatro errores propios que se encontraron y corrigieron en el camino, porque todos daban números confiados y plausibles hasta que algo aguas abajo salió absurdo.

1. Introducción

Cada vuelta, el ingeniero de estrategia tiene que responder una pregunta simple de enunciar y difícil de contestar: ¿entro a boxes ahora o sigo?

Si entra, pierde unos 20 segundos. Si no entra, pierde tiempo con la goma gastada. Y si sale un Safety Car justo después, la decisión que parecía buena se convierte en mala.

Objetivo: construir un sistema que, para una carrera dada, calcule el plan de neumáticos más conveniente y explique por qué.

El sistema entrega, para cada piloto:

- la probabilidad de que convenga 1, 2 o 3 paradas;
- la secuencia de compuestos más probable;
- un rango de vueltas para la primera parada.

Qué queda afuera: la gestión de energía. En 2026 la mitad de la potencia es eléctrica y el manejo de la batería es parte de la estrategia. Pero **la Fórmula 1 no publica esos datos**. Lo verificamos: los canales de telemetría no los traen. Entonces el sistema trabaja con la parte de neumáticos y posición, y esto se aclara desde el principio.

2. Materiales Disponibles

Datos

Se usa la librería `fastf1` de Python, que da los datos oficiales de cronometraje.

Las columnas que importan (compuesto, edad del neumático, número de stint, estado de pista) están completas al 100%. De 2026 salen 14.095 vueltas, 756 stints (tandas con un juego de gomas) y 527 paradas.

Cómo quedó armado el conjunto de datos

`fastf1` tiene un tope de **500 llamadas por hora**. Al bajar varias temporadas de una vez, el tope se alcanza a mitad de camino y las carreras restantes se descartan **sin aviso**. Nos pasó: durante un tiempo el caché tenía 2023 y 2024 cortadas por la mitad y **2025 no estaba en absoluto**, no por criterio sino por accidente.

Se descargó lo que faltaba por tandas. Estado actual:

Temporada	Calendario	Descargadas	Estado
2022	22	22	Completa
2023	22	22	Completa
2024	24	24	Completa
2025	24	24	Completa
2026	23	12	Al día — la temporada está en curso
Total		104 carreras	~112.000 vueltas

Vale la pena dejar constancia de dos cosas que aprendimos ahí:

El caché incompleto sesgaba las estimaciones sin que se notara. De 2023 y 2024 teníamos sólo la primera mitad del año, así que los circuitos de fin de temporada —Austin, México, Brasil, Las Vegas, Qatar— estaban sub-representados. Al completar los datos, la degradación medida del compuesto blando en 2023 pasó de 0,0664 a **0,0403 s/vuelta**. Era un 60% de error, invisible hasta que se comparó.

Un tope de API que descarta en silencio es un riesgo de datos, no una molestia técnica. Por eso el proceso de descarga ahora informa cuántas carreras trajo y cuántas falló.

Qué datos se usan para qué

Al principio decidimos usar **sólo 2026**, porque este año se invirtió el orden de desgaste de los compuestos: el blando pasó de ser el que más se gastaba al que menos. La idea era que entrenar con años anteriores le enseñaría al modelo lo contrario de lo que pasa hoy.

Lo medimos y la decisión estaba mal. Entrenando y probando siempre sobre las mismas carreras de 2026:

Entrenamiento	Vueltas	PR-AUC	Sobre el azar
Sólo 2026	10.143	0,1430	4,24×
Con 2022–2025 sumadas	107.308	0,2238	6,64×

Mezclar mejora un **56%**. El error de razonamiento fue este: la inversión afecta **una** de las diecinueve variables. Las otras —diferencias con los rivales, vuelta del stint, vueltas restantes, estado de pista— sirven igual en cualquier temporada.

Probamos también agregar la temporada como variable, para que el modelo pudiera distinguir las eras. **Empeora** (0,1896 contra 0,2238). Aprende mejor los patrones generales si no se lo invita a separar por año.

Así que la regla no es global, **depende del componente**:

Para qué	Qué datos	Por qué
Entrenar los modelos	Todas las temporadas	Medido: 56% mejor
Tasas de Safety Car por circuito	Todas las temporadas	Con 12 carreras hay una sola visita por circuito; con una temporada es imposible estimarlo
Costo de parar en boxes	Todas las temporadas	Depende del largo del pit lane, no del auto
Desgaste por compuesto	Sólo 2026	Acá sí cambió el comportamiento
Efecto del combustible	Sólo 2026	Los autos son ~32 kg más livianos
Reglamento	Sólo 2026	El artículo B6.3.8 es de este año

Conviene aclarar que el trabajo **sigue siendo sobre 2026**. Lo nuevo es la temporada que se analiza y se pronostica, no la cantidad de datos con la que se entrena. Usar menos datos para poder decir "sólo 2026" habría sido perder precisión a cambio de una frase.

También se usa el **Reglamento Deportivo 2026 de la FIA**, que obliga a usar al menos dos compuestos distintos de seco por carrera. Si no se cumple, el piloto queda descalificado.

Preparación de los datos

Al armar el pipeline aparecieron cuatro problemas que hay que corregir sí o sí:

- 1. Las vueltas de entrada y salida de boxes no sirven para medir ritmo.** Incluyen el paso por el pit lane. Se marcan aparte. Quedan usables el 90% de las vueltas.
- 2. El combustible.** Un auto con más nafta es más lento. Se resta ese efecto para poder comparar la vuelta 8 con la vuelta 45.
- 3. TyreLife no es lo mismo que "vueltas de este stint".** Un piloto que arranca con gomas ya usadas en clasificación empieza la carrera con `TyreLife = 4`. Hay que contar las vueltas dentro del stint aparte.
- 4. Los cambios de goma bajo bandera roja son gratis.** Con la carrera detenida, cambiar neumáticos no cuesta tiempo. En Zandvoort 2026, 21 de 22 pilotos "pararon" en la vuelta 2 por una bandera roja. Si eso se mezcla con las paradas normales, el modelo aprende que parar a veces sale gratis. Se separan en dos etiquetas distintas.

Cómo se separan los datos

Se separa por carrera, no por vuelta. Dos vueltas seguidas de la misma tanda son casi iguales; si quedan una en entrenamiento y otra en prueba, el modelo hace trampa sin querer.

La prueba se hace siempre sobre 2026. No tendría sentido medir en 2024 un sistema pensado para el reglamento de este año.

Se reservan **las últimas 3 carreras de 2026 de las 12 disponibles: el 25%**. Se eligen las más recientes y no tres al azar, porque eso se parece a lo que el sistema tiene que hacer realmente: predecir carreras que todavía no pasaron.

	Carreras	Vueltas	Paradas
Prueba — 2026 R10–12	3 de 12 de 2026 (25%)	3.501	118
Entrenamiento — 2026 R1–9	9	10.143	350
Entrenamiento — más 2022–2025	92	97.165	~3.000

O sea: el 25% de prueba se cumple sobre las carreras de 2026, que es el universo que importa. Las temporadas anteriores **sólo entran en entrenamiento**, nunca en prueba.

Dentro del entrenamiento se valida con `GroupKFold` agrupando por carrera, así ninguna carrera aparece a la vez en entrenamiento y validación.

3. Solución Propuesta

Tres piezas:

1. Simulador de carrera (la base). Simula una carrera vuelta a vuelta: cuánto se degrada cada goma, cuánto cuesta parar, y si sale o no un Safety Car. Se corre miles de veces para ver todos los escenarios posibles. No es una técnica de IA: es el banco de pruebas de las que sí lo son.

2. Algoritmo Genético (la técnica principal — Unidad 3).

Un algoritmo genético busca la mejor solución imitando la evolución: prueba muchas opciones, se queda con las mejores, las combina entre sí y repite el proceso muchas veces.

Acá cada "individuo" es **un plan de carrera completo**. Por ejemplo:

*Arrancar con neumático Medio y parar en la vuelta 18. Poner Duro y parar en la vuelta 43.
Terminar con Blando.*

El procedimiento es:

- 1. Se generan 100 planes al azar.**
- 2. Se le pone una nota a cada uno.** Se simula la carrera con ese plan y se mira en qué posición termina el auto. Cuanto más adelante, mejor la nota. A eso se lo llama **función de aptitud**.
- 3. Se eligen los mejores y se combinan.** De dos planes buenos sale uno nuevo que toma el principio de uno y el final del otro. Eso es el **cruce**.
- 4. De vez en cuando se cambia algo al azar:** alargar un stint dos vueltas, acortarlo, o cambiar el compuesto. Eso es la **mutación**, y sirve para que la búsqueda no se quede siempre dando vueltas alrededor de las mismas ideas.
- 5. Se repite 200 veces.** Los planes malos se descartan, los buenos se mezclan entre sí, y al final queda el mejor que se encontró.

El reglamento actúa como filtro. Un plan que use un solo compuesto de seco queda descartado de entrada, porque en la carrera real sería descalificación. Nunca llega a competir.

Sobre DEAP. La propuesta decía que se iba a usar DEAP, la librería que recomienda la cátedra. La implementación quedó escrita a medida, porque el genoma es de largo variable —un plan tiene una, dos o tres paradas— y necesita reglas de reparación propias: ordenar las paradas, separarlas al menos seis vueltas y forzar una parada cuando la tanda excede lo que la evidencia puede cotizar. Eso no encaja cómodo en los operadores estándar. Portarlo a DEAP no cambia el modelo y queda como tarea pendiente, declarada acá y no escondida.

3. Agente de Aprendizaje por Refuerzo (comparación — Unidad 5).

El algoritmo genético arma el plan **antes de largar**. Pero en una carrera real las cosas cambian: sale un Safety Car, empieza a llover, un rival para antes de lo previsto. Un agente de aprendizaje por refuerzo decide **sobre la marcha**.

La idea es la de enseñarle a jugar a alguien que no sabe las reglas, sólo si le fue bien o mal:

1. **El agente ve el estado de la carrera** en cada vuelta: en qué posición está, cuánto se degradó su goma, a cuánto tiene al de adelante y al de atrás, si hay Safety Car.
2. **Elige una acción:** seguir en pista, o boxear y con qué compuesto.
3. **Se simula la carrera hasta el final** y se le da un **premio**: las posiciones que ganó o perdió.
4. **Se repite miles de carreras.** Al principio decide cualquier cosa. Con el tiempo aprende solo que boxear con Safety Car sale barato y que quedarse demasiado con la goma gastada sale caro. Nadie se lo programó: lo dedujo de los premios.

La demo de la cátedra sobre Blackjack (`Q-Blackjack.ipynb`) es el mismo problema con otra ropa: decidir "pido carta o me planto" bajo incertidumbre, donde seguir conviene hasta cierto punto y después arruina la mano. Cambiar eso por "sigo o boxeo" es casi cambiarle el nombre.

Lo interesante es la comparación: planificar todo de antemano (el genético) contra reaccionar a lo que va pasando (el agente). Cuál gana, y en qué tipo de carreras gana cada uno, es en sí un resultado del trabajo.

El simulador se programa con la interfaz `gymnasium`, que es la que usa la demo de la cátedra, así sirve para las dos técnicas sin escribirlo dos veces.

Herramientas: Python, `fastf1`, `pandas`, `DEAP`, `gymnasium`, `LightGBM`, Google Colab.

Línea futura: una red bayesiana con `pgmpy` para modelar la incertidumbre del Safety Car. Se declara como línea futura y no como promesa: el trabajo es individual y prometer cuatro técnicas para entregar una es peor que proponer dos y cumplirlas.

4. Desarrollo

Lo que ya está hecho

- **El pipeline de datos completo:** descarga, limpieza y cálculo de variables, sobre 103 carreras y 114.414 vueltas.
- **El simulador de carrera**, con todo lo que sortea medido: desgaste, pérdida de boxes, Safety Car, ruido de ritmo y tráfico.
- **El algoritmo genético**, que para cada auto busca el plan de paradas con mejor distribución de resultados sobre cientos de carreras sorteadas.
- **Una interfaz de simulación** que muestra la carrera corriendo con los insights de estrategia encima del trazado, al estilo de las gráficas de la transmisión.
- **Tres cuadernos Jupyter** que dejan el registro reproducible de los datos, la limpieza y cada medición, con el cálculo a la vista y no sólo el resultado.

Lo que falta

- El agente de Aprendizaje por Refuerzo, que era la comparación propuesta.

- Portar el genético a **DEAP**. Está escrito a medida porque el genoma es de largo variable con reglas de reparación, pero DEAP es la herramienta que recomienda la cátedra y conviene alinearse.
- El tráfico de **rezagados**. El 23,1% de los pilotos terminan al menos una vuelta abajo, y la medición actual los excluye por construcción.
- La **ventana de parada** sale hoy de una heurística y debería salir del propio genético.

Lo que encontramos al probar

Esta sección es la más larga a propósito. La mayoría de lo que sigue son resultados negativos o correcciones de errores propios, y son la parte del trabajo que más costó.

Predecir un valor exacto no funciona bien

Lo que intentamos predecir	Nuestro modelo	Predecir siempre la mediana	
Tiempo de vuelta	13,05 s de error	9,39 s	pierde
Degradación por vuelta, sólo 2026	0,937 s	0,716 s	pierde
Degradación por vuelta, con todas las temporadas	0,698 s	0,726 s	gana
Duración de una tanda	8,13 vueltas	8,02	empata
Cantidad de paradas	32,1% de acierto	32,0%	empata

Con sólo 2026 los cuatro intentos perdían o empataban. Al completar los datos, el modelo de degradación **pasa a ganarle al modelo tonto**. O sea que «no se puede predecir» era en parte falta de datos, no una propiedad del problema.

La incertidumbre es más grande que la señal

El dato que justifica todo el diseño: en 2026 el **desvío** del ritmo de caída de una tanda (0,069 s/vuelta en duro, 0,112 en medio, 0,178 en blando) es **más grande que la mediana del ritmo mismo** ($\approx 0,045$ en los tres). Cuánto va a gastar una tanda determinada es, en buena medida, impredecible.

Eso no es un defecto de la medición: es el motivo por el que el sistema devuelve distribuciones y no números.

El desgaste no se distribuye normal

Medida sobre Zandvoort, la curtosis del ritmo de caída da **48,6 en duro, 32,8 en medio y 20,2 en blando**. Una normal tiene cero. Unas pocas tandas catastróficas estiran la cola y hacen que el desvío mienta: el blando tiene desvío 0,66 s/vuelta pero entre el percentil 5 y el 95 va de $-0,18$ a $0,14$. El simulador no asume forma: guarda nueve cortes de la distribución medida y sortea interpolando.

Hubo que ajustar el efecto del combustible, y no fue rápido

La propuesta anterior decía que reajustarlo era «rápido». No lo fue, y el problema es instructivo.

Dos cosas hacen que las vueltas tardías sean más rápidas: el tanque que se vacía y la pista que se engoma. **Dentro de una carrera las dos son lineales en el número de vuelta**, así que son indistinguibles. Un primer diseño metió un efecto fijo por carrera-piloto y regresó contra las dos juntas: no funciona, y no falla a los gritos. Con el largo de carrera fijo dentro del grupo los dos regresores son afines —correlación exactamente $-1,000$ — y el ajuste devolvió **$-0,043$ s/vuelta**, o sea que llevar combustible te haría más rápido.

Para medir desgaste la separación no hace falta: lo que hay que sacarle al tiempo de vuelta es el efecto completo. Ese sí se identifica, y da **$0,056$ s/vuelta** sobre 1.627 carreras-piloto, estable entre 0,047 y 0,062 en las cinco temporadas. Los **$0,035$** que estaban asumidos sacaban apenas el **63%**.

Lo que desbloqueó:

Diferencia de ritmo, mismo piloto y carrera	Con $0,035$	Con $0,056$
medio – duro	+0,189 s/vuelta	–0,024
blando – medio	–0,160	–0,015
blando – duro	+0,187	+0,040

Con la constante vieja el **duro salía el más rápido de los tres en las cinco temporadas**. No era un dato del neumático: el duro se corre en la mediana del 61% de la carrera y el medio en el 26%, y una corrección corta le regala esa ventaja al que corre más tarde.

Corregido, **no hay diferencia de ritmo medible entre compuestos secos**: los tres quedan a menos de 0,04 s/vuelta entre sí y los cuartiles cruzan el cero. Difieren en desgaste y en vida, no en ritmo con goma nueva.

El desgaste medido se aplanar, y es sesgo de supervivencia

Déficit promedio contra vuelta de tanda, sobre 91.000 vueltas: sube hasta la vuelta 20-25 y después **baja**. Ningún neumático hace eso. Los juegos que llegan a las treinta vueltas son los que aguantaron; los que no, se cambiaron.

Consecuencia: los datos **no pueden ponerle precio a una tanda larga**, y lo que dicen de ella es optimista. En vez de inventar una caída sin evidencia, la búsqueda tiene prohibido proponer tandas más largas que el percentil 90 medido —41 vueltas en duro, 31 en medio, 25 en blando—. Es un límite a lo que el modelo puede afirmar, no una afirmación sobre la goma.

El ritmo de caída que trae cada auto casi no predice

Comparando la pendiente de cinco vueltas medida en la vuelta 10 contra lo que esas tandas efectivamente hicieron después, sobre 2.492 tandas: **correlación 0,183**, y la estimación rodante está 3,5 veces sobredispersa. Se encoge al 5%.

Proyectarla cruda no era un error chico: un auto de la foto arrastra -0,549 s/vuelta, que extrapolado a treinta vueltas dice que va a ganar cuatro minutos, y la búsqueda recomendaba un plan que lo hacía **ganar desde noveno**.

La granularidad por circuito no la sostienen los datos

Tres veces seguidas, con tres cantidades distintas, correlacionando la estimación de cada circuito en 2022-23 contra la de 2024-26:

Cantidad	Correlación entre eras	Qué se hizo
Dificultad para adelantar	0,209	Encoger hacia el promedio
Corrección por avance de carrera	0,150	Usar un número global
Costo del tráfico	-0,042	Usar un número global

Con cuatro o cinco carreras por circuito, la dispersión aparente es ruido de una tarde. Lo único que sobrevive es Mónaco, extremo en las tres.

Este patrón hizo caer una afirmación propia. En una versión anterior se dijo que la dificultad para adelantar modula el costo del tráfico, apoyado en agrupar circuitos por dificultad. Midiendo el castigo **por circuito** los dos correlacionan a 0,384 — pero a **0,157 sacando Mónaco**. Y ese agrupamiento le había asignado a Zandvoort un multiplicador de 1,31 cuando su castigo medido propio da 0,68: casi el doble, en la dirección equivocada.

Medir promedios sí funciona

- Parar bajo Safety Car **cuesta 0 posiciones**, contra 2 en carrera normal.
 - Los equipos lo saben: el 36% de las paradas estratégicas de Zandvoort ocurren bajo neutralización, contra 23% global.
 - **La cantidad de paradas depende del compuesto de largada**: largando en duro, 1 parada el 56% de las veces; largando en blando, 2 paradas el 55% y 3 el 26%.
 - El costo efectivo de una parada es **22,6 s en verde y 19,5 bajo Safety Car**, pero el primer cuartil bajo Safety Car es **7,5 s**: reaccionar rápido y reaccionar tarde no son la misma decisión.
-

5. Resultados

Lo que el sistema entrega

Para cada auto, desde la vuelta 30 de 72 de Zandvoort 2026:

	Auto	Plan	Llega	Puntos	Objetivo
P1	ANT	H19-H23	1,88 ± 0,86	19,9	puntos
P5	LEC	M6-H36	2,77 ± 1,29	16,6	puntos
P11	LIN	M6-H36	8,70 ± 1,13	2,9	puntos
P18	COL	H6-H36	16,02 ± 1,34	0,0	posición

Toda la parrilla converge en **una parada**, con confianzas de 0,62 a 0,91. Coincide con lo medido: desde el 42% de la carrera, el 49% de los autos en Zandvoort tiene exactamente una parada por delante.

Qué es «ganar», y por qué no es lo mismo para todos

La aptitud son los **puntos absolutos** en la bandera. Mantener un puesto de puntos gana por construcción: quedarse quinto paga 10 en cada sorteo, y un plan que la mitad de las veces da tercero y la otra mitad octavo ($0,5 \cdot 15 + 0,5 \cdot 4 = 9,5$) no lo alcanza.

Pero para un auto cuyos planes suman cero, ese objetivo está **plano** y la búsqueda no tiene nada que escalar. Medido: un auto 18.º con objetivo puntos termina con la población repartida 0,21 / 0,33 / 0,17 / 0,29 entre una y cuatro paradas, que es ruido. Con objetivo posición converge en una parada al 0,87.

Un auto fuera de los puntos sí puede ganar, pero no con la misma vara, y usar la equivocada no

da una respuesta prudente sino una al azar. Por eso el objetivo es adaptativo: puntos donde son alcanzables, posición donde no.

El resultado principal es negativo

Se comparó el plan del genético contra tres alternativas sin búsqueda, todas evaluadas sobre las **mismas** carreras sorteadas. La más fuerte es «parar en la mitad de lo que queda, al duro».

Desde la vuelta	Gana	Ventaja media
10	6 de 10	+0,11 puntos
20	6 de 10	+0,22
30	5 de 10	+0,18
45	2 de 10	−0,01

El algoritmo genético apenas le gana a una regla de servilleta. Décimas de punto, sin patrón claro por momento de la carrera.

Se probaron dos hipótesis sobre por qué:

- 1. **Que el coeficiente de combustible achatara el desgaste.** Ajustarlo triplicó la ventaja en la vuelta 30, de +0,065 a +0,179 puntos. Era parte, no todo.
- 2. **Que faltara el tráfico.** Se midió (0,544 s/vuelta a menos de un segundo, 23,4% de las vueltas) y se agregó a la aptitud. **No movió nada.**

Qué se mide y con qué se compara

Qué	Cómo se mide	Cuándo está bien
Simulador	Error del modelo de degradación	Mejor que predecir la mediana
Algoritmo genético	Puntos contra una regla simple	Ganar en promedio apenas
Sistema completo	¿La estrategia real cayó dentro del rango?	Pendiente
Reglamento	Planes ilegales generados	Cero

La exactitud no se usa como métrica. «No parar nunca» acierta el 96,6% de las vueltas, y además de inútil **es ilegal**: el reglamento obliga a usar dos compuestos.

6. Análisis de los Resultados

Por qué es tan difícil ganarle a la servilleta

La explicación que queda no es una falla del modelo: es una propiedad de la decisión.

Desde la vuelta 30 el espacio de planes es **efectivamente unidimensional**: una parada, y la única pregunta es en qué vuelta. El objetivo es suave en esa dimensión y su óptimo cae cerca del medio del tramo que queda. Una búsqueda sobre una función suave y unimodal en una variable, cuyo óptimo está cerca del punto medio, va a empatar con «elegí el punto medio» **casi por construcción**.

La servilleta no es una heurística tonta: es una buena aproximación del óptimo en este caso particular. Y el dato lo respalda — el mejor momento medido es la vuelta 20, que es donde dos paradas y la secuencia de compuestos siguen sobre la mesa.

Entonces qué aporta el algoritmo

Se puede decir con precisión, y no es «el óptimo»:

- 1. **La distribución.** Confianza sobre la cantidad de paradas, dispersión del puesto de llegada, y cuánto vale elegir. Eso permite decir «*acá da igual lo que hagas*» cuando da igual, cosa

que una regla no dice. Medido: el mejor plan le gana al peor por **7,89 puntos** para el auto que va primero y por **0,38** para el que va décimo.

2. **Los casos multiparada**, donde no hay punto medio que copiar.
3. **La coherencia con lo medido**: el plan respeta el límite de tanda, la zona de puntos y el reglamento, cosa que una regla no chequea.

Contra trabajos previos

Hay un paper de 2025 (Chaudhary et al.) que hace algo parecido con redes neuronales sobre datos de 2020 a 2024, y llega a $F1 = 0,81$. **Lo nuevo acá no es el problema, es la temporada**: ningún trabajo publicado pudo usar datos de 2026, porque el reglamento cambió este año.

Contra un trabajo propio

En 2025 hice el TP de Inteligencia Artificial sobre este mismo tema: clasificar el compuesto con una red neuronal MLP, con datos de 2020 a 2022.

	TP de IA 2025	Este trabajo
Datos	2020–2022, 782 registros	2022–2026, 114.414 vueltas
Pregunta	¿Qué compuesto?	¿Cuándo parar y cuántas veces?
Técnica	Red neuronal MLP	Algoritmo Genético sobre simulador Monte Carlo
Resultado	0,62–0,70 de exactitud, con sobreajuste	Plan por auto, con su distribución

Aquel trabajo trató de **aprender** qué compuesto elegir y no le fue del todo bien. Este trabajo da una explicación mejor de la que dio la propuesta: no es sólo que el reglamento decida la elección. Es que **no hay diferencia de ritmo medible entre compuestos secos** una vez que se corrige bien el efecto del combustible. No era un problema de la red neuronal: era una pregunta sin respuesta en los datos.

Sobre la comparación con AWS

Las gráficas de la transmisión —«Pit Strategy Battle», «Battle Forecast»— se replicaron con nuestros propios números. La diferencia de fondo no es el modelo: **ellos tienen telemetría de 300 sensores por auto y 1,1 millones de puntos por segundo, y nosotros tiempos por vuelta**. Eso explica por qué pueden ver aire sucio y tráfico con un detalle que acá se aproxima con un promedio. La metodología de AWS no está publicada.

7. Conclusiones

1. **La incertidumbre es más grande que la señal**. El desvío del ritmo de caída de una tanda supera a la mediana del ritmo mismo. Ése es el argumento central para devolver distribuciones y no números, y no es una preferencia de diseño: es lo que dicen los datos.

2. **El algoritmo genético apenas le gana a una regla simple**, y eso hay que decirlo antes que cualquier otra cosa sobre él. La explicación es que desde mitad de carrera la decisión es casi unidimensional y su óptimo cae cerca del punto medio. Lo que el algoritmo aporta con seguridad es la distribución y los casos multiparada, no el óptimo.
3. **La mitad del trabajo fue encontrar errores propios.** El coeficiente de combustible que sacaba el 63% del efecto, el ritmo de caída extrapolado que hacía ganar a un auto desde noveno, el escalado por circuito que duplicaba el tráfico de Zandvoort en la dirección equivocada, la referencia de pérdida de boxes que hacía parecer cara la parada bajo Safety Car. Todos daban números confiados y plausibles hasta que algo aguas abajo salió absurdo.
4. **La granularidad por circuito no la sostienen los datos.** Tres cantidades distintas, tres correlaciones entre ellas de 0,21, 0,15 y -0,04. Con cuatro carreras por circuito, pretender un número propio para cada uno es describir ruido. Sólo Mónaco sobrevive.
5. **El reglamento es una ventaja, no una molestia.** Impide que el sistema proponga algo ilegal, y la exactitud como métrica propondría exactamente eso.
6. **Los datos tienen un techo y conviene nombrarlo.** El desgaste medido se aplana por supervivencia, el tráfico de rezagados queda afuera por construcción, y el aire sucio se aproxima con un promedio porque no hay telemetría. El sistema es honesto dentro de ese techo y lo declara en vez de simular que no existe.

Qué sigue

Acción	Por qué	¿Se puede?
Correr el genético desde antes de largar	Es donde el espacio es multidimensional y debería ganarse el sueldo	Sí, es el test más barato de la afirmación central
Portar a DEAP	Es la herramienta que recomienda la cátedra	Sí, no cambia el modelo
La ventana de parada como salida del genético	Hoy es una heurística de entrada y falla en un tercio de la parrilla	Sí
Tráfico de rezagados	23,1% de los pilotos terminan una vuelta abajo	Requiere comparar por posición y no por vuelta
Agente de Refuerzo	La comparación propuesta: planificar contra reaccionar	Para la Entrega 2
Red bayesiana	Modelar el Safety Car	Sólo como línea futura

Lo que no se va a hacer: más granularidad por circuito, ni más términos en la aptitud esperando que deje de ser plana. Los datos rechazaron lo primero tres veces y lo segundo dio dos negativos seguidos.

Riesgo que se asume: publicar una predicción antes de la carrera puede salir mal en público. Es a propósito. Se evalúa si el rango estaba bien calculado, no si se acertó justo.

Referencias

Chaudhary, S. et al. (2025). *Data-driven pit stop decision support for Formula 1 using deep learning models*. Frontiers in Artificial Intelligence, vol. 8.

Fédération Internationale de l'Automobile (2026). *2026 Formula 1 Sporting Regulations — Section B*, Issue 05. Artículos B6.1.1, B6.1.2 y B6.3.8. <https://www.fia.com/regulation/category/110>

Schäfer, P. et al. (2026). *FastF1*, versión 3.8.3. <https://docs.fastf1.dev/>

Fortin, F. et al. (2012). *DEAP: Evolutionary Algorithms Made Easy*. Journal of Machine Learning Research, vol. 13, pp. 2171–2175.

Ke, G. et al. (2017). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. NIPS 2017.

Pasqualino, F.; Denoya, A.; Sánchez, C.; Sánchez, T.; Lingeri, M. (2025). *Clasificación de Compuesto para la Fórmula 1 utilizando una Red Neuronal Artificial del Tipo Multiperceptrón*. TP N.º 2, Inteligencia Artificial, UTN FRBA. <https://github.com/FrancoPo8/TP2-IA-2025>

Repositorio: (completar)