

Cuadrillas — Predicción de demanda y asignación de recursos para reclamos urbanos

Propuesta B de Trabajo Práctico Integral

Inteligencia Artificial Avanzada — UTN FRBA — 2do Cuatrimestre 2026

Apellido y Nombres	E-Mail	Aporte
Sánchez, Tomás Agustín	(completar)	100%

Fecha de Presentación: (completar)

Resumen

La Ciudad de Buenos Aires recibe cerca de **830.000 reclamos por año**: basura sin retirar, veredas rotas, luminarias apagadas, árboles para podar. Las cuadrillas que los resuelven son limitadas y hay que decidir cuántas mandar a cada comuna.

Este trabajo propone un sistema que hace dos cosas: **predecir cuántos reclamos de cada tipo va a haber en cada comuna la semana que viene**, y con esa predicción **repartir las cuadrillas** para que la gente espere lo menos posible.

Se usa una **red neuronal recurrente** para la predicción y un **algoritmo genético** para el reparto.

1. Introducción

Hoy las cuadrillas se asignan por historial y por criterio del responsable de cada comuna. El problema es que la demanda no es pareja: cambia por época del año, por día de la semana, por barrio y por tipo de reclamo. Las hojas caen en otoño, los escombros aparecen cuando hay obra, las luminarias fallan más en invierno porque están más horas prendidas.

Si se pudiera anticipar dónde va a haber más trabajo, se podría mandar la gente antes en vez de después.

Objetivo

Construir un sistema que:

1. **prediga la cantidad de reclamos** por comuna, categoría y semana;
2. **proponga un reparto de cuadrillas** entre las 15 comunas que minimice la demora total;
3. muestre qué tan confiable es cada predicción.

Qué queda afuera

- El texto de los reclamos: **el dato abierto no lo publica** (lo verificamos, ver sección 2).
- La resolución del reclamo en la calle y el seguimiento del trabajo.
- Reclamos que no son de competencia municipal.

2. Materiales Disponibles

Datos

Se usa el conjunto **Sistema Único de Atención Ciudadana (SUACI)** del portal de datos abiertos de la Ciudad, licencia CC-BY-2.5-AR, publicado por año de **2011 a 2026** en CSV.

Lo descargamos y lo verificamos. Sólo el año 2023 tiene:

Filas	831.373
Columnas	19
Categorías	39
Prestaciones (subtipos)	323
Comunas / barrios	15 / 48
Rango de fechas	2023-01-01 a 2023-12-31, día a día

Columnas reales: nro_solicitud, periodo, categoria, prestacion, tipo, fecha_ingreso, hora_ingreso, comuna, barrio, calle, altura, esquina_proxima, canal, long, lat, genero, estado_general, lat_wgs84, long_wgs84 .

Las categorías más frecuentes en 2023:

Categoría	Reclamos
HIGIENE	320.619
DENUNCIA VIAL	159.882
VEREDAS	67.358
ARBOLADO	60.010
RESOLUCIONES URBANAS	47.126
ALUMBRADO	30.921

Con 15 años publicados, el conjunto completo supera los **10 millones de registros**.

Un hallazgo que cambió la idea original

La primera versión de esta propuesta era distinta: clasificar el **texto** del reclamo con procesamiento de lenguaje natural, para derivarlo automáticamente al área correcta.

Al descargar el dataset se cayó. No hay texto libre: el reclamo ya viene clasificado en `categoria` y `prestacion`. No hay nada que clasificar — la etiqueta está, falta la entrada.

Se deja asentado porque es el tipo de verificación que conviene hacer **antes** de comprometerse con un enfoque, no después.

Lo bueno es que el dataset sirve para algo mejor: tiene **geografía, fecha, hora y canal** de 830.000 reclamos por año. Eso es una serie temporal espacial de primera calidad.

Preparación de los datos

1. Agregar por semana, comuna y categoría. El dato viene reclamo por reclamo; el modelo necesita conteos. Quedan unas 15 comunas × 39 categorías × 52 semanas ≈ 30.000 series-semana por año.

2. Quedarse con las categorías que tienen volumen. De las 39, unas 10 concentran la gran mayoría. Las demás tienen tan pocos casos que predecirlas es ruido.

3. Completar semanas sin reclamos con cero. Si una comuna no tuvo reclamos de arbolado una semana, esa semana vale cero, no "falta el dato".

4. Marcar feriados y estacionalidad. La demanda cae los feriados y sube en ciertas épocas (poda en otoño, por ejemplo). Se agregan como variables.

5. Revisar el 4,9% sin comuna. Casi 41.000 reclamos de 2023 no tienen comuna asignada. Hay que ver si se pueden recuperar por las coordenadas antes de descartarlos.

Cómo se separan los datos

Se separa por tiempo, no al azar. Es una serie temporal: entrenar con datos de después y probar con datos de antes sería hacer trampa.

Se reserva **el último 25% del período** como prueba. Con 2019–2024 eso da:

	Período	Aproximado
Entrenamiento	2019 a mediados de 2023	75%
Prueba	mediados de 2023 a 2024	25%

Dentro del entrenamiento se valida con las últimas semanas del tramo de entrenamiento, nunca con las de prueba.

3. Solución Propuesta

Dos piezas, una por unidad del programa.

Pieza 1 — Predicción de demanda (Unidad 2: Redes Recurrentes)

Una **red neuronal recurrente** que, dadas las últimas N semanas de reclamos de una comuna y categoría, predice las próximas.

Entrada	Serie de reclamos por semana, más día del año, feriados y comuna
Salida	Cantidad esperada de reclamos las próximas 1 a 4 semanas
Modelo	RNN / LSTM en Keras
Comparación	Contra un modelo ingenuo ("la semana que viene igual que esta") y contra el promedio histórico de esa semana

Se elige una red recurrente y no un MLP porque la demanda tiene **memoria**: lo que pasó las semanas anteriores importa, y el orden importa.

Pieza 2 — Asignación de cuadrillas (Unidad 3: Algoritmo Genético)

Con la demanda predicha, hay que repartir un número fijo de cuadrillas entre las 15 comunas.

Cromosoma	Cuántas cuadrillas van a cada comuna. Ejemplo: [3, 5, 2, 4, ...] con 15 posiciones
Aptitud	Demora total estimada: reclamos predichos dividido capacidad asignada, sumado sobre las comunas
Restricción	La suma de cuadrillas no puede pasar el total disponible, y cada comuna necesita un mínimo
Operadores	Cruza de un punto; mutación que mueve una cuadrilla de una comuna a otra

Se usa **DEAP**, la librería que recomienda la cátedra, y se comparan distintos operadores de selección.

Herramientas: Python, pandas , Keras / TensorFlow , DEAP , matplotlib , Google Colab.

Línea futura: agrupar comunas con perfiles de demanda parecidos usando una **red de Kohonen** (SOM, Unidad 2), para armar zonas de servicio en vez de trabajar comuna por comuna.

4. Desarrollo

Lo que ya está hecho

- Descarga y verificación del dataset: 831.373 filas de 2023 revisadas columna por columna.

- Confirmación de que no hay texto libre, que descartó el enfoque original.

Lo que falta

- La agregación semanal por comuna y categoría.
- La red recurrente.
- El algoritmo genético de asignación.

Riesgo principal identificado

La demanda de reclamos urbanos es **fuertemente estacional y bastante regular**. Eso hace que un modelo ingenuo —"la semana que viene se parece a esta"— sea difícil de superar. Es el mismo patrón que encontramos en la Propuesta A: los modelos tontos son buenos rivales.

Por eso el criterio de éxito se define contra ese modelo ingenuo desde el principio, y no en términos absolutos.

5. Resultados

Todavía no hay prototipo. Se define qué se va a medir.

Qué	Cómo se mide	Cuándo está bien
Predicción de demanda	Error absoluto medio (MAE) en reclamos por semana	Mejor que el modelo ingenuo
Predicción de demanda	MAE relativo, para comparar comunas de distinto tamaño	
Asignación de cuadrillas	Demora total simulada	Mejor que el reparto proporcional simple
Asignación de cuadrillas	Comuna peor atendida	Que ninguna quede abandonada
Ambas	Comparación contra el reparto real, si se consigue el dato	

Casos que se documentarán

Se van a mostrar semanas bien predichas y semanas mal predichas. Se espera que las malas sean las de eventos puntuales —un temporal, un feriado largo, un corte de servicio— que por definición no están en la serie histórica.

6. Análisis de los Resultados

Contra modelos simples. Todo resultado se compara contra "la semana que viene igual que esta" y contra "el promedio de esa semana en años anteriores". Sin esa comparación, un MAE solo no dice nada.

Contra trabajos previos. Este dataset ya fue usado públicamente para predecir demanda de servicios urbanos con Prophet (Bits & Bricks). Se comparará contra ese enfoque, que es estadístico clásico, mientras que acá se propone una red recurrente.

Comparación entre las dos piezas. Interesa medir cuánto de la mejora en la asignación viene de predecir mejor y cuánto de optimizar mejor. Se puede aislar corriendo el algoritmo genético con la demanda real conocida en lugar de la predicha.

7. Conclusiones

Esta propuesta ataca un problema con **datos verificados y abundantes**: 831.373 reclamos en un solo año, 15 años publicados, geografía y fecha completas.

1. **El dataset se verificó antes de proponer nada.** Eso descartó la idea original de clasificación de texto, porque no hay texto que clasificar.
2. **Cubre dos unidades del programa:** redes recurrentes para predecir y algoritmo genético para asignar.
3. **Tiene valor real fuera del trabajo práctico:** repartir cuadrillas es un problema concreto de una ciudad concreta.
4. **El riesgo está identificado:** la demanda es regular y el modelo ingenuo va a ser un rival duro.

Qué sigue

Acción	Viabilidad
Agregación semanal por comuna y categoría	Alta, es transformación de datos
Red recurrente	Alta, hay demo de la cátedra (<code>datos-RNN.ipynb</code>)
Algoritmo genético de asignación	Alta, hay demo de la cátedra (<code>CE-*.ipynb</code>)
Red de Kohonen para zonificar	Línea futura

Comparación con la Propuesta A

	A — BoxBox (Fórmula 1)	B — Cuadrillas (reclamos urbanos)
Problema	Cuándo parar en boxes y con qué goma	Cuántos reclamos habrá y cómo repartir cuadrillas
Datos	104 carreras, ~112.000 vueltas	831.373 reclamos por año, 15 años
Verificado	Sí, con mediciones propias	Sí, dataset descargado y revisado
Unidades del programa	3 (Genético) y 5 (Refuerzo)	2 (Recurrentes) y 3 (Genético)
Antecedente propio	Sí — TP de IA 2025 sobre el mismo dominio	No
Antecedente publicado	Paper de 2025 con redes profundas	Análisis público con Prophet
Novedad	Alta: temporada 2026, nadie pudo usar estos datos	Media: el dataset es muy usado
Riesgo	La estrategia depende de eventos impredecibles	El modelo ingenuo es difícil de superar
Utilidad fuera del TP	Baja, es un caso de estudio	Alta, es un problema real de gestión

Preferencia del autor: Propuesta A. Tiene más novedad, ya hay trabajo de datos hecho y verificado, y el pronóstico de carreras futuras permite una validación que no admite trampa. La Propuesta B es más útil en la vida real y tiene un dataset más grande, pero el problema ya fue abordado públicamente varias veces.

Referencias

Gobierno de la Ciudad de Buenos Aires (2026). *Sistema Único de Atención Ciudadana / BA Colaborativa*. Buenos Aires Data, licencia CC-BY-2.5-AR.
<https://data.buenosaires.gob.ar/dataset/sistema-unico-atencion-ciudadana>

Antonio Vazquez Brust (2018). *Predicción de demanda de servicios urbanos con open data + Facebook Prophet*. Bits & Bricks.
<https://bitsandbricks.github.io/post/prediccion-de-demanda-de-servicios-urbanos-con-prophet/>

Fortin, F. et al. (2012). *DEAP: Evolutionary Algorithms Made Easy*. Journal of Machine Learning Research, vol. 13, pp. 2171–2175.

Hochreiter, S. y Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation, vol. 9, n.º 8, pp. 1735–1780.

Chollet, F. et al. (2015). *Keras*. <https://keras.io/>

Repositorio: *(completar)*